

PORTFOLIO 2026

Portfolio by Minsol Kim

김민솔 · Backend Developer

Kafka 파이프라인 · 결제 정합성 · 외부 API 안정화

CONTACT

asle14910@gmail.com | github.com/asle149 | https://asle149.github.io/

ABOUT ↗

PROJECTS ↗

CONTACT ↗

ABOUT

김민솔 | Backend Developer

EXPERIENCE

AI·SW마에스트로 | 17기 연수생 · 백엔드

2026.04 – 현재

- 팀 리더
- 바통: 업무 기록에서 사실을 추출해 검증하는 사내 지식 관리 플랫폼, 백엔드 담당
- 클레임 추출 · 배치 린트 · 확인 질문 · 조직 · 열람 권한 · 업무 이력 · 인수인계

EDUCATION

동국대학교 정보통신공학전공

2021.03 – 2027.02 (졸업 예정)

CERTIFICATE

정보처리기사

SQL개발자(SQLD)

TOEIC Speaking IH(150)

신HSK 4급(253/300)

SKILLS

Java · Spring Boot · JPA · Spring Security

Kafka · PostgreSQL · Redis

AWS EC2 · Docker



바통 (Baton) | 흠어진 업무 기록을 검증된 사내 지식으로



담당

- 문장 단위 사실(클레임) 추출 파이프라인 설계 (Kafka 컨슈머 · DB 작업 큐 · 워커 스레드 풀)
- 배치 린트 · 확인 질문 구현
- 조직 · 계정 · 열람 권한 · 업무 이력 · 인수인계 개발

핵심 성과

- LLM 호출을 작업 큐로 분리, 문서 984건 처리 58.9분 → 30.6분 (48% 단축)
- LLM 호출 동시 처리 8 → 20 (컨슈머 비동기 반환 전환)
- 배치 린트 모순 오탐 88,831 → 71쌍 (동일 100건 데이터, 경계 규칙 보강)

역할

팀장 / 파이프라인 6단계 중 클레임 추출과 배치 린트 담당

기술

Java 21 · Spring Boot 3.5 · Kafka · PostgreSQL(pgvector) · Redis · AWS

검색 챗봇 화면 (답변 문장마다 근거 클레임과 원본 출처 표시)

48%

단축 · 984건 처리

58.9분 → 30.6분

28,009

추출 클레임

문서 984건 처리

99.95%

인용 일치율

26,817건 대조



수집 → 클레임 → 위키 파이프라인 설계



검정 칸 = 직접 설계 · 구현 (클레임 추출, 린트 · 확인 질문)

클레임 추출

의미 단위 조각마다 LLM이 사실 6항목(주어 · 속성 · 값 · 극성 · 범위 · 시점)을 원문 인용과 함께 추출, 호출은 작업 큐 + 워커 풀에서만

린트 · 확인 질문

같은 주어 · 속성끼리 값 → 범위 → 시점 순으로 대조해 모순 · 노후를 찾고, 사람이 답할 것만 확인 질문으로 발행해 위키에 반영

트랜잭셔널 아웃박스

업무 데이터와 발행할 이벤트를 같은 DB 트랜잭션에 저장

역등성 보장

같은 메시지가 두 번 와도 한 번만 반영

단계별 재시도 정책

1분 → 10분 → DLQ → 실패 이력 테이블

읽기 전용 DB 뷰

조회는 뷰로, 상태 변경은 이벤트로만



LLM 호출 지연에 따른 큐 위치 재설계

문제

- LLM 호출 1건당 45~55초간 컨슈머 스레드 점유, 동시 처리 수 = 파티션 수
- max.poll 경계 초과로 같은 문서 4회 재추출 발생

해결

- 1차: 비동기 반환형 컨슈머 전환, 동시 호출 8 → 20
- 2차: 컨슈머가 LLM 응답을 기다리지 않게 LLM 호출만 DB 작업 큐 + 워커 풀로 분리

검토한 대안

- 파티션 증설: 동시 처리 수는 늘지만 스레드 점유는 그대로임
- Share Group(KIP-932 큐 모드) 실험: 파티션 수 제약 없이 동시 29건 확인

48%

단축 · 58.9분 → 30.6분
984건 · 비동기 Kafka → 작업 큐


8 → 20

컨슈머 동시 호출
1차 조치 · 비동기 반환형 컨슈머

개선 전 (컨슈머가 호출 종료까지 대기)



개선 후 (컨슈머는 작업만 등록, 워커가 호출)



RESULTS

핵심 성과

왼쪽 = 같은 문서 984건 · 같은 코드 전후 비교 / 오른쪽 = 실데이터 100건 (GitHub PR 33 · Slack 스레드 67) 처리 지표

큐 재설계 전후 총 처리 시간 (문서 984건)



48 % 단축 · 58.9분 → 30.6분, LLM 호출 3,227 → 3,524회로 작업량은 같음
차이는 대기에서 발생, 카프카 모드는 배치 경계 대기로 실패 동시 65건, 작업 큐 모드는 워커 80이 끝까지 가동

측정 방식: 평균 · p95 · 최댓값 병기, 조치마다 대조군 실행으로 효과 분리
품질 지표: 원문 인용 일치율 99.95% (26,817건 전체 대조) · 긍정 부정 이중 추출 0건


57 초 · 100건 총 처리 시간
문서별 합계 42분 19초

1,556 추출 클레임
위키 228페이지

25 초 · 문서당 평균
p95 38초 · 최댓값 53초

358 건/분 · 1,024건 추출
문서당 13.4초

문서당 처리 시간 분포 (초)



DLQ · 재시도 기반 실패 처리 구조



보호 장치

- 동시 호출 상한(400) 레디스 중앙 집중 · 서킷 브레이커 · 잔액 소진 감지
- 429(요청 한도 초과)는 재시도, 잔액 소진은 즉시 정지
- 메시지별 지터 적용으로 재시도 몰림 방지

트러블슈팅

4 → 0

회 · 서킷 브레이커 오작동
느린 호출 기준 60초 → 300초

116 → 7

회 · 응답 잘림
출력 토큰 상한 초과, 상한 상향

실패 원인별 처리



재시도 여부는 예외 종류가 아니라 실제 원인으로 판정



배치 린트와 확인 질문 (모순 · 노후 판정)

문제

- 같은 사실이 문서마다 다르게 적혀 위키에 모순이 그대로 실림
- 클레임 전수 쌍 비교는 불가, 묶음 경계가 느슨하면 오탐이 수만 건

설계

- 같은 주어 · 속성 그룹 안에서만 쌍 비교, 값 → 범위 → 시점 → 단일값 순 룰체인 판정
- 날짜 · 숫자는 규칙으로 비교, 확신 없으면 무죄, 사전에 없는 속성은 확인 필요
- 사람이 답할 것만 확인 질문으로 발행, 답이 위키를 고치는 유일한 경로

검토한 대안

- 유사도 임계 0.90 상향: 2,286쌍 잔존 → 제외
- 벡터 · 담당자 검색 후보: 별칭 병합 전까지 판정 유보

88,831 → 71

쌍 · 확인 필요 오탐
같은 100건 · 경계 위반 0

973 → 159

건 · 노후 오판정
근거 시각 정밀화

모순

lint:8 · 기록끼리 어긋난 것이 발견돼 올라옴

나중에

모니터링 대시보드의 담당자는 오건우와 정하늘 두 사람인가요, 아니면 정하늘 한 사람인가요?

앞의 기록

모니터링 대시보드의 담당자는 정하늘 한 사람이다.

사실: 모니터링 대시보드의 담당자은(는) 정하늘 (프로젝트: 모니터링 대시보드, 담당: 정하늘)

뒤의 기록

모니터링 대시보드의 담당자는 오건우와 정하늘 두 사람이다.

사실: 모니터링 대시보드의 담당자은(는) 오건우 (부서: 개발, 프로젝트: 모니터링 대시보드, 담당: 오건우)

답변 선택

☐ 앞이 맞습니다

☐ 뒤가 맞습니다

☐ 둘 다 맞습니다

선택하면 관련 사실 2건이 함께 갱신됩니다.

답하면 서버에 저장되고 기록이 갱신됩니다


나중에

답변 저장

확인 질문 화면 (모순 쌍의 앞 · 뒤 기록과 답 선택, 답하면 관련 사실 2건이 함께 갱신)



수수깡 | 한정 수량 수공예품 판매 서버



작품 마켓 화면 (한정 수량 · 선착순 · 품절 표시 · 테스트 결제 환경)

100→0

건 · REQUESTED 잔류
승인 무응답 주입 · 대사 2회

20→0

건 · 경합 오취소
대사 스캔 · 재요청 동시 주입

0

회 · 승인 재호출
결과 미상 100건 · 조회 판정

담당

- 결제사 승인 · 취소 · 조회 API 연동, 결제 장부 · 상태 기계 · 보상 취소 · 조회 대사
- 트랜잭션 경계 설계, 커밋 후 이벤트 발행, 결제 검증 정책 계층
- 재고 차감 동시성 제어, Kafka 이벤트 전달, Docker Compose 배포

핵심 성과

- 승인 전 서버 금액 검증, 조작 요청은 승인 API 호출 0회 · 400
- 외부 호출은 트랜잭션 밖, 결과 미상은 조회 대사로 판정 (재호출 0회)
- 정책 추가 시 서비스 if 분기 0줄 (PaymentPolicy List 주입)

역할

백엔드 설계 · 구현 · 배포

기술

Java 21 · Spring Boot 3.5 · JPA · PostgreSQL · Kafka · OpenFeign · 토스페이먼츠 · Docker Compose · k6



결제 승인 흐름과 트랜잭션 경계

문제

- 결제창 금액은 클라이언트 값, 승인 요청 조작 가능
- 승인 응답을 기다리는 동안 트랜잭션 안에서 대기하면 커넥션 풀 고갈
- 승인 호출 뒤 서버 중단 시 결제 완료 건의 기록이 남지 않음

설계

- 결제위젯 인증 → 서버 승인 2단계, 승인 전 기준가 대조 (불일치 400)
- 커넥션을 붙잡지 않게 승인 API 호출은 트랜잭션 밖, 호출 전 REQUESTED 커밋
- APPROVED 기록은 짧은 자체 트랜잭션, 주문 확정 + 정산 이벤트 발행만 한 트랜잭션

검토한 대안


- 승인까지 한 트랜잭션: 커넥션 점유, DB 롤백으로 외부 결제 승인을 취소할 수 없음 → 제외
- 호출 후 기록: 중단 시 결과 미상 건의 기록이 남지 않음 → 제외

400

응답 · 금액 조작
승인 API 호출 0회

3s / 30s


연결 · 응답 타임아웃
대기 중 커넥션 미점유



빨강 칸: 외부 호출, 트랜잭션 밖 (나머지는 짧은 DB 트랜잭션)



결제 실패 분기와 복구 (상태 기계 · 보상 취소 · 조회 대사)



조회 결과대로만 전이, 승인 재호출 0회

문제

- 외부 호출이 트랜잭션 밖이라 승인 후 중단 · 무응답 시 결과 미상 구간 발생
- 승인 무응답: 재요청은 이중 승인 위험
- 승인 후 확정 실패(TTL 만료): 결제 완료 후 주문 미확정

해결

- REQUESTED 잔류는 10분 주기 스캔이 조회 API로 판정
- 스캔과 재요청 경합도 조건부 UPDATE 한 번 (오취소 20 → 0)
- 확정 실패 시 CANCEL_PENDING 커밋 후 이벤트 발행 → 컨슈머가 취소 API 호출

100→0

건 · REQUESTED 잔류
대사 2회 · 177ms · 23ms

0

회 · 승인 재호출
요청 100건 기준

69

ms · 보상 취소 응답
전부 취소 275ms · 이중 취소 0

10→10

건 · 취소 장애 DLQ 복구
재시도 3회 · DLQ 재투입 · 초과 0



커밋 후 이벤트 발행과 결제 검증 정책 계층

문제

- 커밋 전 발행 시 롤백된 주문의 이벤트만 남는 문제
- 트랜잭션 안에서 브로커 호출 시 메시징 장애가 주문 실패로 전파
- 금액 · 소유자 검증 if 분기가 결제 메서드에 누적

설계

- publishEvent → AFTER_COMMIT 리스너 → Kafka, 3경로 동일 구조
- 보상 취소 기록은 별도 빈에서 새 트랜잭션으로 커밋 (프록시 우회 방지)
- PaymentPolicy 인터페이스 + List 주입, 서비스는 check 순회 호출

검토한 대안


- 아웃박스 테이블: 실지급 이벤트로 확대되면 도입, 현재는 잔류 스캔으로 보완
- 서비스 내부 if 분기: 정책 추가마다 결제 메서드 수정 → 제외

0

줄 · 정책 추가 시 서비스 if 분기
OrderOwnerPolicy 추가 · 인자 1줄

3

경로 · 동일 발행 구조
주문 생성 · 확정 · 보상 취소



커밋 후 발행



롤백 시 리스너 미실행, 발행 없음



핵심 성과 (장애 주입 실측 · 테스트 기준)

장애 주입 4종

시나리오	주입	결과
승인 무응답	100건	대사 177ms · 23ms, 잔류 0, 재호출 0
확정 실패	100건	응답 69ms, 전부 취소 275ms, 이중 취소 0
취소 API 장애	10건	DLQ → 재투입 복구 10, 상한 초과 0
대사 · 재요청 경합	20건	오취소 20 → 0 (승인 전이 조건부 UPDATE)

실제 DB · Kafka 환경, 결제사 API만 mock (외부 응답 지연을 제외한 서버 처리 시간)

측정 방식

- 장애는 결제사 클라이언트에만 주입, DB · Kafka는 실제 환경에서 실행
- REQUESTED 잔류 · 승인 재호출 · 이중 취소 · 오취소 건수를 집계해 판정

100→0

건 · REQUESTED 잔류
승인 무응답 주입 · 대사 2회

0

회 · 승인 재호출
결과 미상 100건 · 조회 판정

20→0

건 · 경합 오취소
스캔 · 재요청 동시 20건

55

건 · 테스트
단위 + SpringBootTest + 장애 주입


스프링 구조

- 생성 · 확정 · 보상 3경로 모두 커밋 후 발행
- 정책 추가 시 서비스 if 분기 0줄
- 외부 API 호출은 트랜잭션 밖, 대기 중 커넥션 미점유

장애 주입 실측 4종에서 REQUESTED 잔류 0 · 이중 취소 0 · 오취소 0 · 상한 초과 0



샤크넷 (SharkNet) | 받은 대출 권유를 공식 데이터로 대조하는 검증 서비스



리포트 화면 (근거마다 공식값과 출처를 붙이고 종합 점수는 만들지 않는다)

8/8

건 · SSE 교차 수신

API 2대 · 0.66~1.08초

0 / 12

건 · 복구 후 유실

슬랙 아웃박스 12건

1.51

초 · 접수→결과 p95

30건/분 · 90건 분포

담당

- 규칙 13종 신설, 알림 수신 서버 (독립 모듈)
- Redis Streams 운영과 다중 인스턴스 대응 (API 2대 · 수신 서버 2대)
- 알림 전용 안드로이드 앱, 공개 URL 외부 헬스체크

핵심 성과

- API 2대에서 끊기던 SSE 알림을 Redis Pub/Sub 중계로 수정 (교차 수신 8/8)
- 알림 규칙 검증 · 보강, 슬랙 · 앱 전달 경로 구축, 장애 주입 검증 (유실 0/12)
- 부하 실측으로 병목을 워커 직렬 처리로 판정, 50건/분에서 포화 확인

역할

팀장 · 관측성 · 알림 · 인프라 (모니터링 스택 · 수신 서버 · Redis Streams)

기술

Java 21 · Spring Boot 4.1 · PostgreSQL 16 · Redis Streams

Python 3.12 · Next.js 16 · Prometheus · Grafana · Docker



API 2대 확장 시 SSE 전달과 스케줄러 중복 실행

문제

- SSE 구독자가 프로세스 메모리에 있어 다른 인스턴스 변경이 안 보임
- 스케줄러와 아웃박스 전송이 인스턴스마다 돌아 같은 일이 중복 실행

해결

- 상태 변경을 Redis Pub/Sub 으로 중계
- 중계가 끊겨도 15초마다 DB 상태를 다시 보내 화면이 멈추지 않게
- 스케줄러는 advisory lock, 아웃박스 작업별로 한 서버만 가져가도록 처리

검토한 대안

- ShedLock: 의존성과 테이블이 늘어 제외, advisory lock 으로 충분
- Redis 중계만 사용: Redis 가 단일 장애점이 되어 제외

8/8

건 · 교차 SSE 수신
API 2대 · 0.66~1.08초


0

건 · 수신 서버 2대 중복 전송
40건 분담 20/20

개선 전 (구독자 목록 = 프로세스 메모리)



개선 후 (로컬 전달 먼저, Redis Pub/Sub 다음)



중계 차단 실험: 재전송 없음 0/8, 15초 재전송 8/8



알림 파이프라인 구축과 장애 주입 검증



감시 지표 3종과 감시 이유 (서비스 안정성)

- 원장 신선도: 최신 변경 내역을 놓쳐 잘못 판정할 수 있음
- 큐 대기 시간: 늘어나면 워커 포화, 처리 지연의 첫 신호
- 단계별 p95: 밀리면 사용자가 결과를 기다리는 시간이 늘어남

장애 주입: 수신 서버의 슬랙 전송 실패

- Alertmanager 가 슬랙으로 직접 전송, 복구 뒤 125초에 대기 0 · 유실 0 / 12
- Alertmanager 는 전송 실패 시 대체 수신처가 없어 처음부터 두 곳에 보냄


95

초 · 주입 → 발화
for 1m + 평가 주기

0 / 12

건 · 복구 뒤 유실
145초에 해소

워커 처리량 실측 (LLM 실패율)



같은 요청 집합의 접수→결과 p95 · FAILED 0

- 추출 단계 p95 는 세 조건 모두 1.9초, 늘어난 것은 큐 대기 시간
- 병목은 워커 직렬 처리 (XREADGROUP count=1), 50건/분 포화

52

건/분 · 계산 상한 (60 ÷ 1.15초)
50건/분 포화 실측과 일치



김민솔 · Backend Developer
asle14910@gmail.com
github.com/asle149

CONTACT

